

Rozważania nad drzewami

Stanisław Frelik

24 października 2023

1 O celu pracy

Oczywistym jest, że *strojenie* parametrów stanowi rzecz niezbędną, aby dany model uczenia maszynowego, jakkolwiek wymyślny czy podparty teorią matematyczną, stał się czymś więcej niż przewidywaniami kiepskiej wróżki. Stąd celem tej pracy jest sprawdzenie jak poszczególne parametry modelu drzewa decyzyjnego wpływają na jego jakość predykcyjną.

2 O przyjętej metodologii i pewnych ograniczeniach

Niełatwo jest się uczyć bez żadnych materiałów "dydaktycznych". Ich rolę w tej pracy będą spełniać enigmatyczne zbiory danych $\mathbf{X}$ i $\mathbf{y}$, rozumiane odpowiednio jako zbiór *features* i *target*. Badanie dokładności drzewa decyzyjnego na zbiorze treningowym i testowym (podział 7:3) przeprowadzimy wykorzystując między innymi 5-krotną krosvalidację. Interesować nas będą takie parametry drzew decyzyjnych jak:

1. Kryterium podziału (entropia, indeks Gini'ego)
2. Głębokość drzewa
3. Minimalna liczba obserwacji w liściu
4. Minimalna liczba obserwacji potrzebna do rozgałęzienia

Napotykamy tutaj dwa "problemy". Po pierwsze, generowanie i testowanie dużych liczb drzew stanowi wyzwanie obliczeniowe. Ominięcie tego problemu jest co najmniej trudne, ponieważ do wyciągnięcia wniosków na temat badanych parametrów potrzebujemy odpowiednią ilość danych, która pozwoliłaby nam na przeprowadzenie ich statystycznie wiarygodnej analizy. Po drugie, przyjęta metodologia zupełnie nie jest gęsta w przestrzeni wszystkich testów jakim moglibyśmy poddać drzewo. W szczególności ograniczamy się do zbiorów $\mathbf{X}$ i $\mathbf{y}$, które mogą faworyzować pewne parametry ponad inne oraz nie będziemy badać wszystkich możliwych kombinacji wszystkich możliwych wartości wszystkich możliwych parametrów - byłoby to wyjątkowo czasochłonne i wymagające obliczeniowo. Posłużymy się tutaj w dużej mierze *matematyczną intuicją*, aby wskazać coś, co faktycznie, z dużym prawdopodobieństwem, może mieć "sens".

3 Eksperyment

W celu zbadania optymalnych wartości poniższych parametrów przeprowadzimy wielokrotnie (przynajmniej 100 razy) 5-krotną krosvalidację dla różnych zestawów parametrów i policzymy dla nich wartości funkcji *cross-val-score* (z parametrami $cv=5$ i $scoring=auc$). Następnie z otrzymanych wyników policzymy średnią arytmetyczną oraz odchylenie standardowe aby wybrać statystycznie najlepszą wartość parametru. Tak wybrany parametr posłuży do zbadania korzystnych wartości kolejnych parametrów. Nasuwa się pytanie, czy taki system zapewni nam faktyczną optymalność badanych parametrów. Oczywiście nie! Niemniej, alternatywą było by badanie wszystkich możliwych kombinacji wartości interesujących nas parametrów...

3.1 Indeks Gini'ego vs entropia

Domyślnym parametrem metody *DecisionTreeClassifier* jest indeks Gini'ego. Wykonane obliczenia wykazują, iż **entropia** skutkuje większą dokładnością modelu.

```
Entropy: 0.8243 accuracy with a standard deviation of 0.000000
Gini: 0.8182 accuracy with a standard deviation of 0.001529
```

3.2 Głębokość drzewa

Wiemy, że domyślnie drzewa generowane przez *DecisionTreeClassifier* są dość "głębokie". Wpływa to negatywnie na czas obliczeń. Wykonane testy wskazują, iż optymalną wartością tego parametru jest **8**. Warto odnotować, iż poniższe eksperymenty przebiegały niejako dwustopniowo - najpierw badaliśmy różne wartości parametrów aby zaobserwować globalną tendencję, a następnie z kilku "dobrych" wartości wybieraliśmy te najlepsze poprzez dokładniejszą analizę.

```
Max depth = 6.0: 0.8522 accuracy with a standard deviation of 0.000000
Max depth = 8.0: 0.8726 accuracy with a standard deviation of 0.000000
Max depth = 10.0: 0.8640 accuracy with a standard deviation of 0.000000
Max depth = 12.0: 0.8492 accuracy with a standard deviation of 0.000000
```

3.3 Minimalna liczba obserwacji w liściu i minimalna liczba obserwacji potrzebna do rozgałęzienia

Powyższe parametry są ze sobą stosunkowo ściśle związane dlatego rozważymy je wspólnie. Domyślne wartości parametrów *min-samples-leaf* i *min-samples-split* odpowiednio wynoszą (tylko) jeden i dwa. Oznacza to, że drzewa są generowane tak długo, jak tylko można "gdzieś podzielić". Nie jest to zjawisko korzystne. Stanowi ono obliczeniowe wyzwanie. Ponadto, dla dostatecznie małych liczb obserwacji, rozgałęzianie odbywa się, z dużym prawdopodobieństwem, losowo. Eksperyment pokazuje, że optymalne wartości tych parametrów to: **40** i **20** odpowiednio.

```
Min sample leaf = 36.0: 0.8781 accuracy with a standard deviation of 0.000000
Min sample leaf = 40.0: 0.8782 accuracy with a standard deviation of 0.000000
Min sample leaf = 44.0: 0.8777 accuracy with a standard deviation of 0.000000
-----
Min sample split = 18.0: 0.8825 accuracy with a standard deviation of 0.000000
Min sample split = 20.0: 0.8825 accuracy with a standard deviation of 0.000000
Min sample split = 22.0: 0.8825 accuracy with a standard deviation of 0.000000
Min sample split = 24.0: 0.8825 accuracy with a standard deviation of 0.000000
```

4 Analiza jakości predykcyjnej wybranego modelu

Na podstawie sekcji 3 dochodzimy do konkluzji, iż optymalnymi wartościami parametrów w modelu drzewa decyzyjnego (dla danych **X** i **y**) są:

1. *criterion* = *entropy*
2. *max-depth* = 8
3. *min-samples-leaf* = 40
4. *min-samples-split* = 20

Przy czym pozostałe wartości parametrów pozostawiamy domyślne. Mając już dostrojone parametry przejdziemy do faktycznej oceny modelu na podstawie danych treningowych (przypominamy podział 7:3).

4.1 Macierz pomyłek

Popelnianie błędów jest niejako wpisane w uczenie maszynowe. Niemniej to jakie błędy popełniamy może nam coś powiedzieć o tym jak zachowuje się nasz model, na przykład czy częściej popełnia błąd I lub II rodzaju. Metodą na wizualizację powyższego jest *macierz pomyłek*. Poniżej prezentujemy ją ze standardową interpretacją.

$$\begin{bmatrix} 2347 & 681 \\ 572 & 2400 \end{bmatrix}$$


4.2 Dokładność, czułość i precyzja

Znamy wiele miar dokładności modelu opartych na macierzy pomyłek. Poniżej prezentujemy najpopularniejsze. Czy otrzymane wyniki są satysfakcjonujące? Trudno powiedzieć.

```
accuracy: 0.7911666666666667
recall: 0.8075370121130552
precision: 0.7789678675754625
```

4.3 Krzywa ROC, wartość AUC

Krzywa ROC, a w szczególności pole pod tą krzywą stanowią *złoty standard* oceny nie tylko drzew decyzyjnych. Całe powyższe rozważania można sprowadzić do pytania: kto ma większe AUC? Dlatego poniżej prezentujemy jak wygląda krzywa ROC dla naszego modelu i danych oraz wartość AUC.



5 Podsumowanie

Prawdziwym wyzwaniem adepta uczenia maszynowego jest stwierdzenie czy, **tak naprawdę**, otrzymany model jest jakkolwiek użyteczny poza rozważaniami czysto teoretycznymi, w "zaczysku domowym". Dany problem wydaje się mieć dwa rozwiązania. Zawsze możemy spróbować znaleźć "lepsz" model - w znaczeniu, na przykład, większej wartości AUC. Oczywiście nie jest to rozwiązanie bezbolesne, a temperatura procesora cały czas rośnie. Innym rozwiązaniem jest rzucenie naszemu modelowi więcej danych - zarówno do jeszcze szczerzej zakrojonych testów, jak i do użycia jako dane testowe - stosunkowo szybko okazałoby się czy trafiliśmy w dziesiątkę czy znacząco spudłowaliśmy. Istnieje też trzecia opcja - zacząć od "nowa", to znaczy wybrać inne sposoby oceny modelu lub zupełnie inny model, ale to jeszcze historia na następny raz...

Dziękuję za uwagę!