

Uciążliwi sąsiedzi

Stanisław Frelik

19 grudnia 2023

1 Cel pracy

Wszechwiedzące, przewidujące przyszłość 'maszyny' to wynalazek ostatnich lat, a nawet miesięcy. Ich zaskakujące tempo rozwoju porównywalne jest jedynie do ich stopnia skomplikowania - zawilej wewnętrznej struktury, niezrozumiałej w pełni nawet dla jej twórców. W tej pracy chcielibyśmy jednak spróbować naśladować inne istoty, które przez wieki stawiały podwaliny dzisiejszej cywilizacji - ludzi. W szczególności zaczerpnijmy inspiracji z tego jak człowiek radzi sobie z rozwiązywaniem nowych problemów. Jedną z takich metod jest próba zestawienia nowego wyzwania z tym, co już się wydarzyło, co jest nam dobrze znane i wyciągnięcie stąd wniosków na temat optymalnego sposobu zaradzenia owemu problemowi. Umiejętność gromadzenia zasobów wiedzy (zarówno przekazywanych ustnie, pisemnie czy ówczesznie cyfrowo) stanowi bezpośredni powód sukcesu jaki odniósł i wciąż odnosi *homo sapiens*.

Tak zainspirowani przejdziemy zatem do implementacji powyższej idei w języku zer i jedynek - do implementacji **metody k najbliższych sąsiadów** (będziemy używać skrótu kNN - k nearest neighbors). Następnie przetestujemy wypracowaną metodę oraz wyciągniemy wnioski na jej temat.

2 Problem implementacji

W tej części opiszemy poglądowo proces implementacji metody kNN. W szczególności opiszemy jakie argumenty przyjmuje nasza funkcja `knn()` i co siedzi "w środku". Ogół implementacji przebiegał zgodnie z otrzymanymi instrukcjami.

Funkcja `knn()` przyjmuje 5 argumentów, w kolejności:

1. macierz rzeczywistą $\mathbb{X}$, typu $n \times p$
2. n elementowy obiekt $\mathbf{y}$, gdzie y_i reprezentuje etykietę odpowiadającą obserwacji $\mathbb{X}[i,]$
3. macierz rzeczywistą $\mathbb{Z}$ typu $m \times p$, reprezentującą m punktów w $\mathbb{R}^p$ (zbiór testowy)
4. liczbę całkowitą $1 \leq k \leq n$, oznaczającą liczbę najbliższych sąsiadów biorących udział w poszukiwaniu etykiety odpowiadającej punktom ze zbioru testowego
5. wartość rzeczywistą $p \geq 1$, domyślnie równą 2, określającą, która metryka Minkowskiego L_p będzie używana do poszukiwania najbliższych sąsiadów. Uwaga, możliwe jest, by $p = \infty$

Korzystając z dobroci pakietu *sklearn* i metody *train-test-split* rozważane w dalszej części pracy przykładowe zbiory danych będziemy za ich pomocą odpowiednio dzielić a następnie stosować do nich naszą funkcję `knn()`.

Jednak nawet 'najsprytniejsza' funkcja nic nie poradzi jeżeli otrzyma niewłaściwe argumenty. Co za tym idzie, znaczący fragment w implementacji został poświęcony zadbania o to, aby metoda kNN mogła zostać wykonana. Funkcja `knn()` sprawdza zarówno poprawność 'wymiarów' argumentów, jak i ich typ. Wytrywały *data scientist* mógłby pokusić się o zdefiniowanie odległości dla danych tekstowych, ale my oszczędzimy sobie tej 'zabawy'. Niemniej, zgodnie ze sztuką, funkcja `knn()` normalizuje przyjmowane argumenty $\mathbb{X}$ i $\mathbb{Z}$ z pomocą średniej i wariancji.

Następnie przechodzimy do implementacji samej metody kNN, w której wartym wspomnienia jest używana przez nas odległość od najbliższych sąsiadów - odległość Minkowskiego. Poniżej prezentujemy jej matematyczny opis, w zależności od parametru p dla $X = (x_1, x_2, \dots, x_n)$ i $Y = (y_1, y_2, \dots, y_n)$:

- jeśli $p = \infty$ to wówczas:

$$D(X, Y) = \max_i |x_i - y_i|$$

- w przeciwnym przypadku:


$$D(X, Y) = \left(\sum_{i=1}^n (|x_i - y_i|)^p \right)^{1/p}$$

Zwrócimy jeszcze uwagę na to, jak rozstrzygamy spory, to znaczy jak wybieramy spośród 'równoodległych' sąsiadów. W takiej sytuacji losujemy z jednostajnego rozkładu dyskretnego który sąsiad dostanie w danej iteracji etykietę najbliższego.


3 Przeprowadzone testy

W celu zbadania poprawności i dokładności zaimplementowanej metody kNN przeprowadzimy serię testów na różnych zbiorach danych i dla różnych parametrów. Istotnie zbadamy jakie wyniki zwraca funkcja `knn()` dla trzech zbiorów z $\mathbb{R}^2$ wraz z etykietami dla punktów (w przypadku dwóch i trzech klas) oraz porównamy otrzymane wyniki ze zbiorem testowych etykiet w wyniku czego otrzymamy ułamek poprawnych klasyfikacji - dalej określamy jako 'dokładność'. Zbadamy skuteczność implementacji dla metryk L_1, L_2, L_∞ . Chcemy zwrócić szczególną uwagę na wybór badanych wartości k - to znaczy liczby sąsiadów branych pod uwagę podczas przypisywania etykiety dla nowej obserwacji. Wydawałoby się, iż nie powinna być ona zbyt duża, jednak jak zostało pokazane (między innymi na wykładzie :)) większe wartości k (proporcjonalne do wielkości zbioru uczącego) pozytywnie wpływają na stabilność modelu kNN oraz zmniejszają ryzyko przeuczenia (jest to prawdziwe jednak dla klas zbalansowanych). Stąd wniosek, iż słusznym podejściem w celu osiągnięcia jak najlepszego modelu kNN byłoby zbadanie optymalnej wartości k poprzez krosvalidację (z uwzględnieniem dużych wartości k !).


W celu uzyskania wizualnych intuicji (w końcu rozważamy tylko dane z $\mathbb{R}^2$ więc przyjemnie się je rysuje) poniżej prezentujemy użyte do testowania `knn()` przykładowe zbiory danych. Zostały one wygenerowane poprzez losowanie 500 punktów z rozkładu jednostajnego ciągłego na przedziale $(0, 10)$. Następnie w różny sposób poszczególnym punktom zostały nadane etykiety klas co jest widoczne poprzez odpowiednie pokolorowanie tych punktów.



Rysunek 1: Liniowo separowalne



Rysunek 2: Trzy klasy



Rysunek 3: Chaos

4 Odtwarzanie

Na rozgrzewkę zbadamy czy uzyskana funkcja `knn()` posiada własność odtwarzania - to znaczy, czy dla $k = 1$ i tożsamyh zbiorów treningowych i testowych jesteśmy w stanie do idealnego odtworzenia wektora etykiet. Poniżej prezentujemy wyniki tego eksperymentu:

L_p/dane	rys. 1	rys. 2	rys. 3
$p = 1$	0.906	0.620	0.614
$p = 2$	0.906	0.620	0.614
$p = \infty$	0.906	0.620	0.614

Tabela 1: Ocena odtwarzalności

Żądana przez nas własność odtwarzania, jak widzimy w tabeli 1. jest istotnie niespełniona. Jest to zarówno niepokojące jak i interesujące. Widzimy, że stosunek odtworzeń nie zależał od wybranej metryki. Warto zaznaczyć, iż podane zostały wartości, które obrazowały pewnien trend. Dla tak małej liczby branych pod uwagę sąsiadów nasza funkcja zachowywała się wyjątkowo niestabilnie, a wahania wynosiły nie raz kilkadziesiąt procent skuteczności odtworzeń. Nie wyczerpuje to w pełni odpowiedzi na zaskakująco niskie wyniki dla danych z rysunków 2. i 3. jednak takie zachowanie zaimplementowanej przez nas metody kNN pozostaje dla nas tajemnicą.

5 Dane liniowo separowalne

L_p/k	1	2	5	7	10	25	35	65	100
$p = 1$	0.827	0.833	0.840	0.827	0.847	0.847	0.847	0.847	0.847
$p = 2$	0.913	0.860	0.920	0.920	0.913	0.913	0.913	0.913	0.913
$p = \infty$	0.907	0.847	0.920	0.920	0.913	0.913	0.913	0.913	0.913

Tabela 2: Ocena poprawności dla danych z rysunku 1.

Bardzo nam miło, że dla danych z rysunku 1. nasza implementacja metody kNN zwraca zadowalające wyniki oscylujące, w zależności od użytej metryki, na poziomie 85-90 procent (tabela 2.). Zauważamy wspomnianą wcześniej zależność od wyboru k - obserwujemy istotny spadek dokładności w okolicach wartości 2-7. Natomiast wraz ze wzrostem wartości k dokładność asymptotycznie dąży do wyższych wartości. Co więcej, największa dokładność została w tym przypadku uzyskana przy przyjęciu metryki maksimum.

6 Dane 'okrągłe'

L_p/k	1	2	5	7	10	25	35	65	100
$p = 1$	0.387	0.413	0.607	0.647	0.640	0.647	0.667	0.667	0.667
$p = 2$	0.580	0.547	0.613	0.600	0.620	0.640	0.653	0.647	0.647
$p = \infty$	0.580	0.520	0.607	0.600	0.607	0.640	0.647	0.647	0.647

Tabela 3: Ocena poprawności dla danych z rysunku 2.

W tej części zwiększamy poziom 'trudności'. Wygenerowany przykład zilustrowany na rysunku 2. to dane, które nie zostały w oczywisty sposób rozseparowane, ponadto poszczególnym 'kołom' została przypisana jedna z trzech klas (inaczej niż w pozostałych przypadkach). W tabeli 3. prezentujemy otrzymane dokładności dla różnych metryk i wartości k . Natychmiast obserwujemy ogólny spadek dokładności, co było do przewidzenia. Ponadto dla małych k dokładność pozostawia wiele do życzenia. Niemniej, prawa strona tabeli 3. prezentuje nie tak tragiczny obraz sytuacji. Otrzymaliśmy 'eksperta' nieznacznie lepszego od rzutu monetą a to już coś...

7 Chaos nie dane

Przejdźmy do ostatniego eksperymentu - a co się stanie jeśli dane nie są w żaden sposób uporządkowane? Zgodnie z przewidywaniami funkcja `knn()` zupełnie nie radzi sobie z danymi z rysunku 3. co dobitnie

L_p/k	1	2	5	7	10	25	35	65	100
$p = 1$	0.527	0.507	0.467	0.467	0.480	0.540	0.520	0.553	0.547
$p = 2$	0.527	0.487	0.467	0.467	0.427	0.540	0.520	0.553	0.553
$p = \infty$	0.527	0.547	0.460	0.467	0.480	0.507	0.527	0.553	0.553

Tabela 4: Ocena poprawności dla danych z rysunku 2.

przedstawia tabela 4. Niemniej warto było się przekonać, iż nasza implementacja metody kNN ma jeszcze daleko do osiągnięcia statusu 'wszechwiedzącego bóstwa' i bliżej jej do wspomnianego w tytule tej części mitologicznego *chaosu*.

8 Podsumowanie i wnioski

Zaczynając od najmniej przyjemnej informacji stwierdzamy, iż nasza implementacja metody k najbliższych sąsiadów nie spełniła naszych oczekiwań. Co więcej, wraz ze wzrostem 'skomplikowania' problemu jej skuteczność drastycznie malała. W pewnym sensie można stwierdzić, iż założenie naśladowania ludzkich ekspertów było zbyt mocne - nie zawsze da się rozwiązać nowy problem wyłącznie na podstawie obserwacji wcześniejszych, potrzebujemy ponadto pewnej metawiedzy o otaczającym nasz świecie aby skutecznie sobie z nimi radzić. Niemniej praca z metodą kNN zaowocowała wieloma pozytywnymi lekcjami, nie tylko odnośnie pisania tego typu funkcji czy testowania własnych implementacji (i pisania w $\text{\LaTeX}$). Intensywne rozważania nad pozornie prostym zagadnieniem jakim jest (w idei) metoda kNN pokazały ogrom kierunków, w których możnaby dalej zabrać ten projekt. Przemielona wiedza oświeciła niezliczone detale i technikalnia jakie należy wziąć pod uwagę, gdy próbujemy wyłapać z chaosu porządek i wzorce. Biorąc pod uwagę fakt, iż wariacje na temat metody kNN są w stanie aktywnego rozwoju i prowadzone są na ich temat badania, możemy tylko liczyć, że w przypadku spotkania najbliższego sąsiada w przyszłości ta praca będzie stanowiła solidny punkt startowy do poznania nie tylko tego najbliższego, ale wszystkich k sąsiadów...

Dziękuję za uwagę!