

Logistyka kredytów

Stanisław Frelik

21 listopada 2023

1 Cel pracy

Naturalnym problemem z jakim mierzy się każda instytucja finansowa udzielająca kredyty jest ocena potencjalnych klientów pod względem ryzyka tego, iż owy klient kredytu nie spłaci. Chcielibyśmy więc potrafić sklasyfikować nowego klienta ze względu na ryzyko jakie niesie dla naszej instytucji. Oczywiście jest, że na zdolność kredytową może wpływać wiele czynników, na przykład historia kredytowa klienta, jego aktualne zatrudnienie, wiek czy status matrymonialny. Co za tym idzie, takie zadanie jest bardzo trudne do rozwiązania "na palcach". Z pomocą przychodzi nam metody uczenia maszynowego, w szczególności modele regresji logistycznej oraz modele maszyn wektorów podpierających. Z ich pomocą będziemy chcieli zbudować "tebańską wyrocznię".

2 O danych i strukturze pracy

Do pracy posłużą nam [dane](#) pewnej instytucji finansowej zawierające po 20 cech od 1000 klientów wraz z ich oceną (warto tutaj zaznaczyć, iż jesteśmy dość konserwatywni w udzielaniu kredytów, to znaczy zdecydowanie ograniczamy szanse na przyznanie kredytu klientowi faktycznie niezdolnemu do jego spłacenia).

Większość z kolumn z powyższej ramki danych zawiera dane nienumeryczne. Nasze metody nie radzą sobie w takich sytuacjach. Stąd na wstępie modyfikujemy ramkę danych tak aby dalej pracować tylko na danych numerycznych. Z tak przygotowanymi danymi przejdziemy do budowy 4 modeli uczenia maszynowego:

1. Modelu regresji logistycznej bez regularyzacji
2. Modelu regresji logistycznej z regularyzacją "l1"
3. Modelu regresji logistycznej z regularyzacją "l2"
4. Modelu maszyn wektorów podpierających

Z pomocą funkcji *skm.GridSearchCV* (10-krotnej krosvalidacji) znajdziemy najbardziej optymalne parametry każdego modelu (względem miary dokładność). Następnie zbadamy ich dokładność, czułość, precyzję i wartość AUC oraz narysujemy dla nich krzywą ROC. Warto zaznaczyć, iż nie wszystkie regularyzacje wspierają wszystkie możliwe parametry modelu regresji logistycznej. Co za tym idzie w każdym z przypadków będziemy przeszukiwać trochę inną siatkę parametrów modelu. Ponadto parametry, które nie były dostrajane w procedurze opisanej powyżej pozostawiamy jako domyślne.

3 Optymalne parametry modeli regresji logistycznej

Przeprowadzony eksperyment wykazał, iż optymalne parametry modelu regresji logistycznej bez regularyzacji to:

- fit intercept: True
- multi class: auto
- max iter: 1600
- solver: newton-cholesky

Dla modelu regresji logistycznej z regularyzacją "l1" optymalne parametry wynoszą:

- fit intercept: True
- multiclass: auto
- C: 1
- max iter: 1000
- solver: liblinear
- tol: 1e-07

Natomiast dla regresji logistycznej z regularyzacją "l2":


- fit intercept: True
- solver: liblinear
- dual: False
- max iter: 1000
- C: 0.1
- multi class: auto
- tol: 1e-06

4 Ocena modeli regresji logistycznej

Poniżej prezentujemy ocenę dostrojonych i wytrenowanych modeli regresji logistycznej względem miar wymienionych wcześniej oraz ich krzywe ROC. Zauważamy, iż wszystkie modele zostały ocenione dość podobnie. Widzimy, iż zdecydowanie odznaczają się bardzo wysoką czułością.

scoring/penalty	NONE	l1	l2
accuracy	0.777	0.767	0.767
precision	0.796	0.793	0.789
recall	0.92	0.906	0.915
AUC	0.784	0.784	0.78

Tabela 1: Ocena poszczególnych regularyzacji



5 Podsumowanie regresji logistycznej, wnioski z regularyzacji l1

Przyjrzyjmy się bliżej modelowi z regularyzacją "l1". Wiemy, że taki dobór regularyzacji prowadzi do "automatycznej selekcji zmiennych". Oznacza to, że cechy, które nie wpływają na poprawę zdolności predykcyjnych modelu są "ściągane do zera" (w przeciwieństwie do regularyzacji "l2", która wraz ze zwiększaniem wagi penalizacji "ściąga" wszystkie parametry). Co za tym idzie, możemy myśleć o tych cechach jako nieistotnych i nie brać ich pod uwagę w kolejnym rozdziale (w szczególności wybraliśmy te cechy, dla których wartość współczynnika w modelu regresji logistycznej z regularyzacją "l1" wynosi poniżej 0.001 (wartość ustalona przez autora) i wyrzuciliśmy z ramki danych odpowiadające im kolumny). Okazuje się, że nieistotne cechy to na przykład:

- Czas na jaki wzięliśmy kredyt
- Rata kredytu jako procent zarobków
- Liczba zaciągniętych kredytów

6 Maszyny wektorów wspierających

W tym rozdziale dostroimy hiperparametry i wytrenujemy na opisanych powyżej danych model maszyn wektorów wspierających. Z powodu dużej liczby cech (22) niestety nie będziemy mogli przedstawić bardzo eleganckiej geometrycznej wizualizacji działania maszyn wektorów wspierających.

Podobnie jak w rozdziałach o regresji logistycznej przeprowadziliśmy eksperyment przy użyciu funkcji *skm.GridSearchCV*, a następnie wytrenowany model ocenimy tymi samymi miarami co wcześniej. Wyniki prezentują się następująco:


1. Najlepsze wartości parametrów:

- C: 6
- gamma: scale
- tol: 2

2. Ocena modelu:

- accuracy: 0.723
- precision: 0.77
- recall: 0.868
- auc: 0.734

3. Krzywa ROC:



7 Podsumowanie

W podsumowaniu chcielibyśmy wyciągnąć pewną wiedzę z wykonanej pracy aby móc ją stosować w przyszłości. Odpowiedzi na pytanie o najlepszy z 4 rozważanych modeli uczenia maszynowego, biorąc pod uwagę powyższą analizę, precyzyjnie nie uzyskaliśmy. Warto zaznaczyć jeszcze raz bardzo przydatną własność modelu regresji logistycznej z regularyzacją "l1". Dzięki niej dalsza praca, w szczególności z maszynami wektorów wspierających, była dużo mniej bolesna (przede wszystkim dla rozgrzanego procesora). Może to świadczyć o tym, iż poprawnym podejściem byłoby rozważanie kilku różnych modeli równolegle, wyciąganie z nich na bieżąco wniosków i stosowanie ich do uzyskania jak najlepszych właściwości predykcyjnych. Odpowiadając na postawiony cel pracy, czy udało się nam zbudować "tebańską wyrocznię"? Wydaje się, że nie do końca, jednak jest to najprawdopodobniej właściwa droga do osiągnięcia tego celu. Ale to jeszcze historia na następny raz...

Dziękuję za uwagę!